Licenciatura em Engenharia Informática

Sistemas Multimédia

Codificação de Dados sem Perdas

Telmo Reis Cunha

Departamento de Eletrónica, Telecomunicações e Informática

Universidade de Aveiro – 2018/2019

1. Codificação de Dados

- No módulo anterior foi analisada a codificação ao nível do símbolo, através de códigos binários.

- Agora será analisada a codificação de dados (guardados em ficheiro, ou constituindo mensagens a ser transmitidas).

- Por exemplo, pode-se tirar partido de, num texto, várias palavras (sequências de símbolos) aparecerem repetidas várias vezes, codificando o texto de uma forma mais compacta (a repetição de tais palavras é, assim, codificada de uma forma mais eficiente).

- Consideram-se, apenas, esquemas de codificação de dados sem perda de informação.

2. Codificação RLE (Run-Length Encoding)

- Esta técnica de codificação consiste em representar cada ocorrência de um símbolo seguido do número de vezes que ele surge repetido nessa posição.

- Por exemplo, a sequência de símbolos:

AAAAAAAABBBBCCCCCCCCCCBBABBB

- Seria representada por:

A8B4C10B2A1B3

- Evidentemente, esta representação só se torna útil para casos em que o número de símbolos é baixo, surgindo, com elevada probabilidade, muitos símbolos repetidos ao longo dos dados.

2. Codificação RLE (Run-Length Encoding)

- Uma aplicação onde esta técnica tem bastante utilidade é na codificação de imagens monocromáticas (imagens a preto-e-branco), como é o caso do fax.

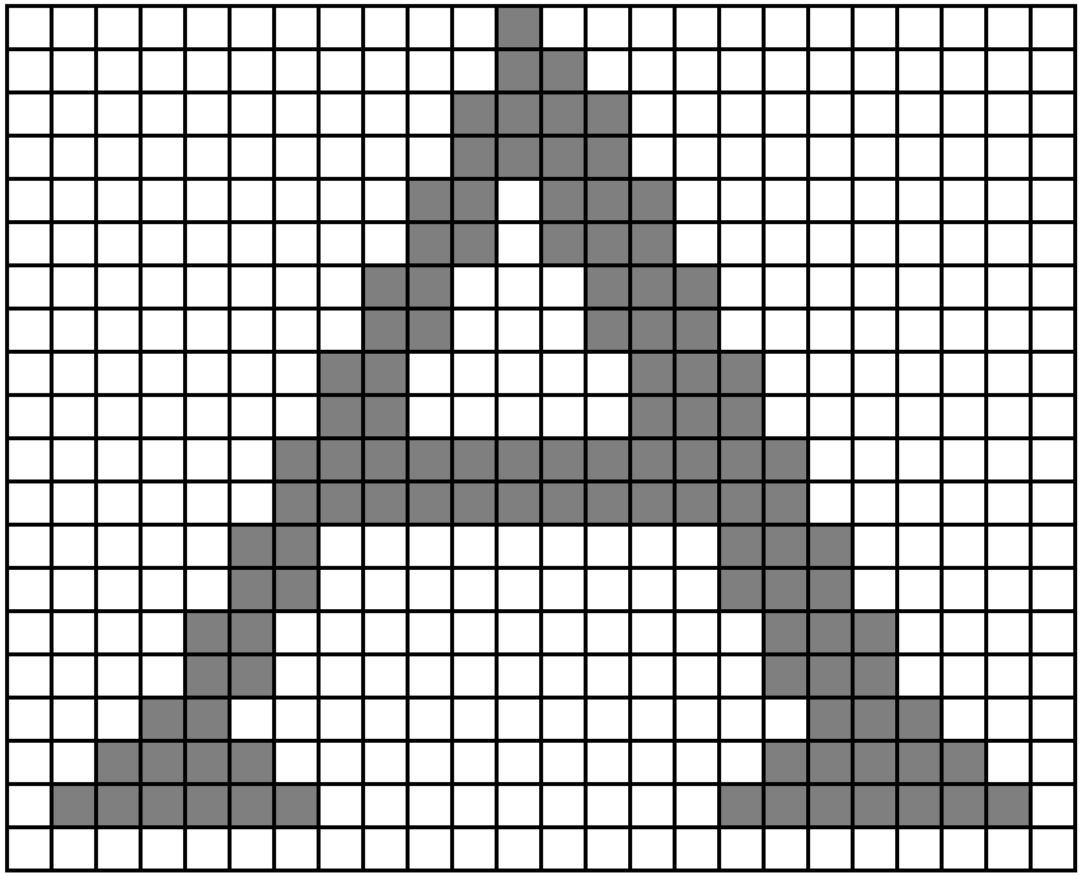

20x24=480 bits

85 nibbles = 340 bits

3. Codificação Baseada em Dicionário

- Uma classe de codificadores, usualmente usados na compressão de texto (mas não só), considera a existência de um dicionário de sequências símbolos (conhecido na compressão e descodificação).

- Essas sequências de símbolos (palavras) estão identificadas no dicionário através de um número (índice ou endereço).

- Na compressão (codificação), à medida que as palavras vão sendo sequencialmente encontradas no texto, são representadas pelo índice correspondente no dicionário.

- Os códigos podem considerar um dicionário fixo, e podem ir criando o dicionário à medida que codificam/descodificam o texto.

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Abraham Lempel e Jacob Ziv propuseram, em 1977, um codificador que cria dinamicamente o dicionário considerado – este ficou conhecido por código (ou compressão) LZ77.

- Este método (juntamente com o LZ78) é reconhecido como um marco na técnica de compressão de dados e ficheiros, tendo sido baseada na observação de que num texto é frequente ocorrerem repetições de sequências de carateres.

- Os algoritmos LZ77 e LZ78 foram usados como base para formar técnicas de compressão de dados que hoje estão muito disseminadas, como o GIF e o algoritmo DEFLATE (que é usada nas codificações PNG e ZIP).

3. Codificação Baseada em Dicionário

Codificador LZ77:

- O algoritmo LZ77 é:
  - Considere-se uma janela deslizante de N carateres em sequência (usualmente, $N = 2\ kB, 4\ kB$ ou $32\ kB$), do próprio texto a comprimir.
  - Uma outra janela, denominada janela de observação, com M carateres, é usada para pesquisar sequências de carateres que existam na janela deslizante.
  - Se existir tal sequência, ela é substituída no texto comprimido pelo **par distância-comprimento** referente à janela deslizante.

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Exemplo ilustrativo (com $N = 8$ e $M = 4$):

  - Sequência a codificar:

AEABCEHCDABCHDEABCD

  - Primeiro, copia-se a primeira janela deslizante (dicionário inicial):

AEABCEHC

  - Depois, considera-se a janela de observação que se lhe segue (DABC) e tenta-se encontrar a máxima sequência comum na janela deslizante.
  - Esta será ABC, que não inclui o primeiro carater (que é copiado para a mensagem comprimida).

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Exemplo ilustrativo (com $N = 8$ e $M = 4$):

  - Sequência a codificar:

AEABCEHCDABCHDEABCD

  - O sequência comprimida fica, neste ponto:

AEABCEHCD

  - E a janela deslizante avança um carater (EABCEHCD).
  - A nova janela de observação é, então: ABCH.
  - A sequência ABC está na janela deslizante, começando na posição 2. Logo, a sequência comprimida fica, agora:

AEABCEHCD(2,3)

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Exemplo ilustrativo (com $N = 8$ e $M = 4$):

  - Sequência a codificar:

AEABCEHCDABCHDEABCD

  - A janela deslizante avança 3 carateres: CEHCDABC
  - Assim, como a janela de observação: HDEA
  - Como não há sequências coincidentes na janela deslizante, copia-se o próximo carater:

AEABCEHCD(2,3)H

  - E as janelas avançam mais um carater:
  - EHCDABCH e DEAB (e assim sucessivamente).

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Exemplo ilustrativo (com $N = 8$ e $M = 4$):

  - Sequência a codificar:

AEABCEHCDABCHDEABCD

Sequência:	J. deslizante:	J. de obs.:
• AEABCEHCD(2,3)HD	HCDABCHD	EABC
• AEABCEHCD(2,3)HDE	CDABCHDE	ABCD
• AEABCEHCD(2,3)HDE(3,3)	BCHDEABC	D
• AEABCEHCD(2,3)HDE(3,3)D		

3. Codificação Baseada em Dicionário

Codificador LZ77:

- Muitas vezes, o índice indicado não é referente à posição inicial da janela deslizante mas sim à posição do carater que se está analisar.
- Ou seja, no par distância-comprimento, a distância é interpretada como o número de carateres que precedem o carater em análise.

- Se a dimensão da janela deslizante é pequena, torna-se fácil perder repetições de sequências que estejam um pouco afastadas no texto.
- Se essa dimensão é elevada, os índices de distância requerem um número elevado de bits (retirando eficiência à compressão).

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

- Trata-se de uma versão melhorada do LZ78, proposta por Lempel, Ziv e Terry Welch em 1984.
- Este considera logo desde o início a presença de um dicionário.

Algoritmo:

- Constitui-se o dicionário com todos os símbolos do código.
- Começa-se a percorrer os dados até que a presente sequência w mais o carater seguinte não esteja no dicionário.
- Adiciona-se w mais o carater seguinte ao dicionário (o dicionário vai aumentando de tamanho).
- Sequências encontradas no dicionário são substituídas pelo índice correspondente.

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

Dicionário inicial:

Símbolo	Índice
#	0
A	1
B	2
…	…
Z	26

5 bits por símbolo

- Início da análise dos dados: a sequência TO não está no dicionário, pelo que se adiciona ao dicionário.

TO	27
O…	28

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

- Na sequência de saída coloca-se o índice correspondente ao símbolo T.
- Testa-se, agora a sequência seguinte: OB
- Também não está no dicionário, pelo que é adicionada (e o índice de O é enviado para a sequência de saída).

Dicionário:

TO	27
OB	28
B…	29

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

- Próxima sequência: BE (adiciona-se ao dicionário, e B para a saída).

Dicionário:

TO	27
OB	28
BE	29
E…	30

- Próxima: EO (para o dicionário)
  (E para a saída)

TO	27
OB	28
BE	29
EO	30
O…	31

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

- Próxima sequência: OR (para ao dicionário, e O para a saída).

Dicionário:

TO	27
OB	28
BE	29
EO	30
OR	31
R…	32

A partir daqui são necessários 6 bits por símbolo

- Próxima: RN (para o dicionário) ETC.

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

- Quando chega ao 10º carater, encontra-se a primeira sequência no dicionário: coloca-se o índice 27 na saída.
- Adiciona-se TOB ao dicionário.

E continua-se o procedimento até ao final dos dados.

Naturalmente, o dicionário não pode crescer indefinidamente.

TO	27
OB	28
BE	29
EO	30
OR	31
…	…
TT	35
TOB	36
B…	

3. Codificação Baseada em Dicionário

Codificador LZW (Lempel-Ziv-Welch):

Exemplo:

TOBEORNOTTOBEORTOBEORNOT#

- No final, a sequência de saída fica:

20	15	2	5	15	18	14	15	20	27	29	31	36	30	32	34	0
T	O	B	E	O	R	N	O	T	TO	BE	OR	TOB	EO	RN	OT	#
5	5	5	5	5	5	6	6	6	6	6	6	6	6	6	6	6

- Número total de bits: $6 \times 5\text{bit} + 11 \times 6\text{bit} = 96\ \text{bits}$
- Antes da compressão: $25 \times 5\text{bit} = 125\ \text{bits}$
- Reduz-se em cerca de 22% o volume de dados.

4. Codificadores para Imagem sem Perdas

- Existem vários algoritmos de compressão, sem perda de informação, destinados à compressão de imagens.

- Alguns exemplos são:
  - **JBIG**: compressão para imagens binárias (fax, por exemplo) – implementa RLE, seguido de codificação de Huffman.
  - **JPEG-LS**: Usa predição linear entre pixéis adjacentes e codificação de Huffman sobre o erro.
  - **GIF**: Usa o código LZW, mas restringe a palete de cores ao máximo de 256.
  - **PNG**: Usa predição linear e o algoritmo DEFLATE (que se baseia no LZ77 e no LZW) para comprimir o erro. Admite "*true color*".