

# Capítulo 4

## Processamento de Consultas

---

### **Tem como função:**

- Transformar uma query de alto nível (cálculo relacional) numa query equivalente de baixo nível (álgebra relacional)
- Escolher uma estratégia de processamento de queries com menor custo de recursos computacionais
- Buscar entre várias transformações equivalentes a mais correta

No caso da BD distribuída, a consulta deve ser estendida com operações de comunicação e otimização.

Existem 3 passos para atingir:

- Analisar e Traduzir: Verificar a sintaxe e as relações  
Traduzir (decompor) numa expressão de álgebra relacional equivalente
- Otimização: Plano de avaliação ideal (localização dos dados)
- Execução: Execução do plano e avaliação

O sucesso de SGBDR (Sistemas de Gestão de Base de Dados Relacionais) é devido a:

- Linguagem de queries declarativas e fácil
- Tecnologias de processamento de queries avançada

A transformação deve atingir:

- Correção: Fácil de alcançar através do mapeamento bem definido do cálculo relacional para álgebra relacional
- Eficiência: É difícil de alcançar pois é difícil selecionar a estratégia de execução que minimiza o consumo de recursos

## Processos de Consultas Distribuídas

### • Objetivos:

- Dar ao utilizador a impressão de que a query é realizada numa única BD
- Transformar uma query de alto nível definida para um BD distribuída (que parece ser uma única BD) numa estratégia de execução eficiente (expressa em linguagem de baixo nível) a ser executada em BD locais

### • Otimização de Consultas:

- Para uma mesma consulta de alto nível podem existir muitas estratégias de execução diferentes - aquela que minimiza o consumo de recursos deve ser a escolhida

### • Medidas de Consumo:

- Minimizar o custo de: I/O + CPU + custo de comunicação
  - redes de comunicação mais rápidas (LAN e WAN)

- **Operações da álgebra relacional:**

- A álgebra relacional é a base para expressar o processamento de uma consulta
- A complexidade dos operadores da álgebra relacional afetam diretamente o tempo de execução de uma query e ditam alguns princípios úteis ao processamento
- A complexidade é definida pela cardinalidade
- Os operadores mais seletivos devem ser executados primeiro (reduzem a cardinalidade)
- Operadores devem ser ordenados pela complexidade de forma crescente (produto cartesiano deve ficar para último)

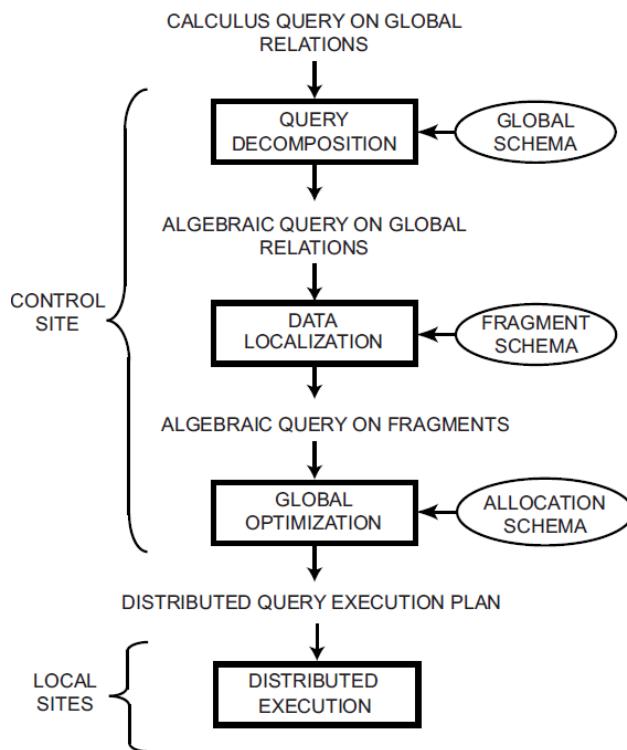
## Problemas no processo de Otimização das Queries

Problemas a considerar na otimização das queries:

- Técnica: procura exaustiva, heurística, híbrida
- Tempo: quando a query é otimizada (estática, dinâmica)
- Estatísticas: número de tuplos, o seu tamanho e o número de colunas
- Decisão dos sites: centralizado, distribuído, misturado (distribuição de como os elementos estão dispostos)
- Topologia da Rede: LAN ou WAN
- Fragments replicados
- Uso de semijoins: reduz o tamanho de *joins* e o custo de comunicação

<b>Técnica</b>	<ul style="list-style-type: none"> <li>- Procura exaustiva - elevado custo para manter mas ótimo</li> <li>- Heurística - baixo custo mas não ótimo</li> <li>- Híbrida - é construída uma query estática e a adaptação é abalido em tempo de execução</li> </ul>
<b>Tempo</b>	<ul style="list-style-type: none"> <li>- Estático <ul style="list-style-type: none"> <li>- A otimização da query ocorre em tempo de compilação</li> <li>- O custo pode ser amortizado por conta das várias execuções da query</li> <li>- É apropriado para usar com o método de pesquisa exaustiva</li> </ul> </li> <li>- Dinâmico <ul style="list-style-type: none"> <li>- A otimização da query ocorre em tempo de execução</li> <li>- É possível a qualquer ponto da execução escolher a melhor estratégia de execução considerando o conhecimento preciso dos resultados</li> <li>- <u>Desvantagem</u>: A otimização fica cara</li> <li>- É apropriado para usar com o método de pesquisa híbrido</li> </ul> </li> </ul>
<b>Decisão dos Sites</b>	<ul style="list-style-type: none"> <li>- Centralizado <ul style="list-style-type: none"> <li>- Um único site toma a decisão</li> <li>- Requer o conhecimento de toda a BD distribuída</li> </ul> </li> <li>- Distribuído <ul style="list-style-type: none"> <li>- Vários sites tomam a decisão</li> <li>- Requer apenas informações locais</li> </ul> </li> <li>- Híbrida <ul style="list-style-type: none"> <li>- Um único site toma a decisão mais importante e os restantes tomam decisões locais</li> </ul> </li> </ul>
<b>Estatística</b>	<ul style="list-style-type: none"> <li>- As estatísticas para a otimização de consultas são definidas com base nos fragmentos, incluindo a cardinalidade e tamanho dos fragmentos, bem como o tamanho e o número de valores distintos de cada atributo</li> <li>- Atualizações periódicas das estatísticas levam a uma “re-otimização” no caso da otimização estática</li> </ul>
<b>Fragments Replicados</b>	<p>Para fins de fiabilidade é útil ter fragmentos replicados</p> <ul style="list-style-type: none"> <li>- Alguns algoritmos de otimização exploram a existência de fragmentos replicados em tempo de execução visando diminuir o custo de comunicação</li> <li>- O algoritmo torna-se mais complexo porque aumenta o número de possibilidades de estratégia em execução</li> </ul>
<b>Uso de semijoins</b>	<p>Quando o principal componente de custo é a comunicação, um <i>semijoin</i> é útil para melhorar o processamento, pois reduz o tamanho dos dados a serem trocados pela rede. Porém, pode resultar num aumento de troca de mensagens e do tempo de processamento local</p>

# Camadas de Processamento de Consulta



- A entrada é uma consulta definida sobre relações globais (a distribuição fica transparente).
- Os 3 primeiros níveis mapeiam a query de entrada num plano de execução de query distribuída.
  - A decomposição da consulta e a localização dos dados correspondem à reescrita da query.
  - As 3 primeiras atividades são executadas por um site de controlo central e usam informações sobre o esquema armazenado no diretório global.
  - O 4º nível é responsável pela execução da query distribuída (o plano é executado e a resposta é retornada ao utilizador)
  - isto é feito pelos sites locais e pelo site de controlo

## Decomposição de consultas

- Decomposição da query de cálculo algébrico numa consulta algébrica sobre relações globais
- As técnicas utilizadas por essa camada são as de um SGBD centralizado

<b>Nominalização</b>	A query de cálculo é reescrita de forma normalizada
<b>Análise</b>	A query normalizada é analisada semanticamente, de forma a que as queries incorretas sejam rejeitadas
<b>Simplificação</b>	As queries corretas são simplificadas, eliminando predicados redundantes
<b>Restruturação</b>	A query de cálculo é reestruturada para uma query algébrica

## Localização dos Dados

- Localiza os dados e determina os fragmentos que estão envolvidos na query e transforma a query distribuída numa query sobre fragmentos

<b>Entrada</b>	Query algébrica sobre relações distribuídas
<b>Objetivo</b>	Localizar dados com o uso de informações de distribuição de dados
<b>Resultado</b>	Determina que fragmentos estão envolvidos na query e transforma a query distribuída numa query sobre fragmentos

## Otimização de Queries Globais

- Encontrar a melhor estratégia de execução possível. A estratégia consiste em ordenar as operações incluindo as de comunicação para minimizar o custo computacional

<b>Entrada</b>	Query algébrica sobre os fragmentos
<b>Objetivo</b>	<ul style="list-style-type: none"><li>- Encontrar a melhor estratégia de execução possível</li><li>- A estratégia de execução pode ser descrita como operações de álgebra relacional e primitivas de comunicação para transferência de dados entre sites</li><li>- A estratégia consiste em ordenar as operações incluindo as de comunicação, para minimizar o custo computacional</li></ul>
<b>Resultado</b>	Plano de execução de consulta distribuída

## Execução Distribuída

- Otimização da query usando um repositório local, usando algoritmos de sistemas centralizados

<b>Entrada</b>	Operações de álgebra relacional
<b>Objetivo</b>	Otimização da query usando um repositório local
<b>Resultado</b>	A otimização local usa algoritmos de sistemas centralizados