Capítulo 5

Decomposição de consultas e Localização de dados

Decomposição

Decomposição de consultas:

4 fases:

- Normalização: Mapeamento do cálculo da consulta SQL para formulários normalizados (ambos referem-se às relações globais)
- Análise: Detetar e rejeitar consultas incorretas
- Eliminação de redundâncias (Simplificação): Sem redundância
- Reescrita: Transformar o resultado para um final

Normalização

Transformar a consulta numa forma normalizada

A parte mais importante é a transformação dos qualificadores (clausulas WHERE)

Lógica clássica:

- Forma Normal Conjuntiva

$$(p_{11} \vee p_{12} \vee \cdots \vee p_{1n}) \wedge \cdots \wedge (p_{m1} \vee p_{m2} \vee \cdots \vee p_{mn})$$

- Forma Normal Disjuntiva

$$(p_{11} \wedge p_{12} \wedge \cdots \wedge p_{1n}) \vee \cdots \vee (p_{m1} \wedge p_{m2} \wedge \cdots \wedge p_{mn})$$

EXEMPLO

Encontre os nomes dos funcionários que trabalham no projeto P1 por 12 ou 24 meses

EMP(ENO, ENAME, TITLE)
PAY(TITLE, SAL)
PROJ(PNO, PNAME, BUDGET)
ASG(ENO, PNO, RESP, DUR)

```
SELECT ENAME
FROM   EMP, ASG
WHERE  EMP.ENO = ASG.ENO
AND    ASG.PNO = "P1"
AND    DUR = 12 OR DUR = 24
```

Forma Normal Conjuntiva

$$\text{EMP.ENO} = \text{ASG.ENO} \wedge \text{ASG.PNO} = \text{“P1”} \wedge (\text{DUR} = 12 \vee \text{DUR} = 24)$$

Forma Normal Disjuntiva (Pode ser redundante)

$$(\text{EMP.ENO} = \text{ASG.ENO} \wedge \text{ASG.PNO} = \text{“P1”} \wedge \text{DUR} = 12) \vee$$
$$(\text{EMP.ENO} = \text{ASG.ENO} \wedge \text{ASG.PNO} = \text{“P1”} \wedge \text{DUR} = 24)$$

Análise

Espécie de compilador que serve para:
- Detetar erros de syntax
- Detetar se uma consulta está correta semanticamente
- Detetar tipos incorretos
    - nomes de atributos e relações
    - tipos de valores/atributos em operações

onde a consulta pode ser representada por meio de um grafo

Grafo de consulta	Grafo de junção
- Operadores (Seleção, Projeção, Junção) - Nós: Operandos - Nó especial: RESULT - Aresta: junção ou projeção	- Apenas as junções são consideradas - Útil na fase de otimização de consultas

EXEMPLO - SEMÂNTICA CORRETA

Encontre os nomes e as responsabilidades dos programadores que trabalham no projeto CAD/CAM por mais de três anos

EMP(ENO, ENAME, TITLE)
PAY(TITLE, SAL)
PROJ(PNO, PNAME, BUDGET)
ASG(ENO, PNO, RESP, DUR)

```
SELECT ENAME, RESP
FROM   EMP, ASG, PROJ
WHERE  EMP.ENO = ASG.ENO
AND    ASG.PNO = PROJ.PNO
AND    PNAME = "CAD/CAM"
AND    DUR ≥ 36
AND    TITLE = "Programmer"
```

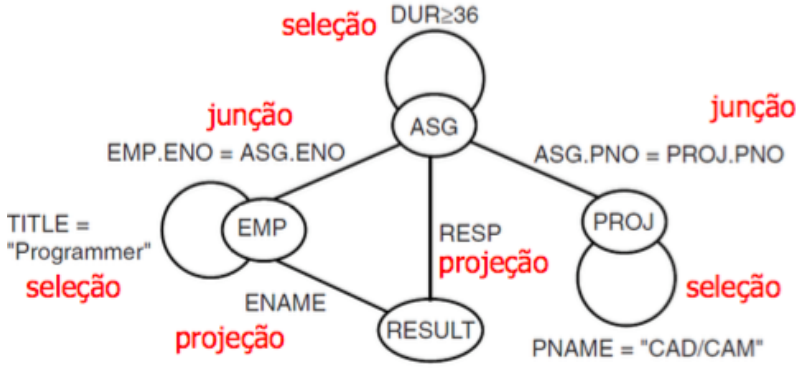

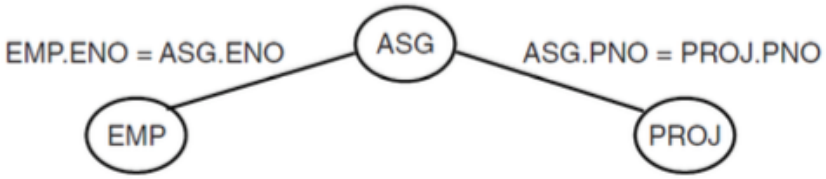

EXEMPLO - SEMÂNTICA INCORRETA

Uma consulta é semanticamente incorreta
se o seu grafo de consulta não for conetado

EMP(ENO, ENAME, TITLE)
PAY(TITLE, SAL)
PROJ(PNO, PNAME, BUDGET)
ASG(ENO, PNO, RESP, DUR)

```
SELECT ENAME, RESP
FROM   EMP, ASG, PROJ
WHERE  EMP.ENO = ASG.ENO
AND    PNAME = "CAD/CAM"
AND    DUR ≥ 36
AND    TITLE = "Programmer"
```

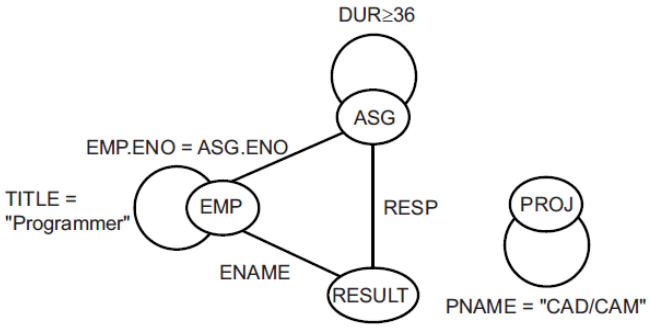

Soluções:

- Rejeitar a consulta
- Supor um produto cartesiano implícito (ASG X PROJ)
- Deduzir o predicado ASG.PNO = PROJ.PNO

Eliminação de Redundância

Simplificação das consultas eliminando as redundâncias.
As redundâncias são muitas vezes devido a restrições de integridade semântica (forma normal conjuntiva ou disjuntiva)

Regras de Idempotência	Operadores Lógicos
$p \wedge p \Leftrightarrow p$ $p \vee p \Leftrightarrow p$ $p \wedge true \Leftrightarrow p$ $p \vee false \Leftrightarrow p$ $p \wedge false \Leftrightarrow false$ $p \vee true \Leftrightarrow true$ $p \wedge \neg p \Leftrightarrow false$ $p \vee \neg p \Leftrightarrow true$ $p_1 \wedge (p_1 \vee p_2) \Leftrightarrow p_1$ $p_1 \vee (p_1 \wedge p_2) \Leftrightarrow p_1$	$p_1 \wedge p_2 \Leftrightarrow p_2 \wedge p_1$ $p_1 \vee p_2 \Leftrightarrow p_2 \vee p_1$ $p_1 \wedge (p_2 \wedge p_3) \Leftrightarrow (p_1 \wedge p_2) \wedge p_3$ $p_1 \vee (p_2 \vee p_3) \Leftrightarrow (p_1 \vee p_2) \vee p_3$ $p_1 \wedge (p_2 \vee p_3) \Leftrightarrow (p_1 \wedge p_2) \vee (p_1 \wedge p_3)$ $p_1 \vee (p_2 \wedge p_3) \Leftrightarrow (p_1 \vee p_2) \wedge (p_1 \vee p_3)$ $\neg(p_1 \wedge p_2) \Leftrightarrow \neg p_1 \vee \neg p_2$ $\neg(p_1 \vee p_2) \Leftrightarrow \neg p_1 \wedge \neg p_2$ $\neg(\neg p) \Leftrightarrow p$

p1: title="Programmer",
p2: title="Elect. Eng."
p3: ename="J. Doe"

```
SELECT TITLE
FROM   EMP
WHERE  (NOT (TITLE = "Programmer")
AND    (TITLE = "Programmer"
OR     TITLE = "Elect. Eng.")
AND    NOT (TITLE = "Elect. Eng."))
OR     ENAME = "J. Doe"
```

$$(\neg p_1 \wedge (p_1 \vee p_2) \wedge \neg p_2) \vee p_3$$

$$(\neg p_1 \wedge \underline{(p_1 \vee p_2) \wedge \neg p_2}) \vee p_3$$

$$(\underline{\neg p_1 \wedge p_1} \wedge \neg p_2) \vee (\neg p_1 \wedge \underline{p_2 \wedge \neg p_2}) \vee p_3$$

$$(\underline{\neg p_1 \wedge ((p_1 \wedge \neg p_2) \vee (p_2 \wedge \neg p_2))}) \vee p_3$$

$$(false \wedge \neg p_2) \vee (\neg p_1 \wedge false) \vee p_3$$

$$false \vee false \vee p_3$$

p3: ename="J. Doe"

```
SELECT TITLE
FROM   EMP
WHERE  ENAME = "J. Doe"
```

Reescrita

Etapas:

- Transformação direta da consulta de cálculo relacional para álgebra relacional
- Reestruturação da consulta algébrica para melhorar o desempenho

A consulta em álgebra relacional é representada por uma árvore de operadores

Árvore de Operadores:

- Folhas = Relações
- Não folhas = Relações intermédias
- Sentido: folhas até à raíz

1. Cada relação é uma folha
   - FROM
2. Raiz é a operação de projeção
   - SELECT
3. Qualificações são sequências das folhas até a raiz (operações relacionais)
   - WHERE

EXEMPLO

Selecionar todos empregados que não são "J.Doe" que trabalham no projeto CAD/CAM por 1 ou 2 anos

```
SELECT ENAME
FROM   PROJ, ASG, EMP
WHERE  ASG.ENO = EMP.ENO
AND    ASG.PNO = PROJ.PNO
AND    ENAME != "J. Doe"
AND    PROJ.PNAME = "CAD/CAM"
AND    (DUR = 12 OR DUR = 24)
```

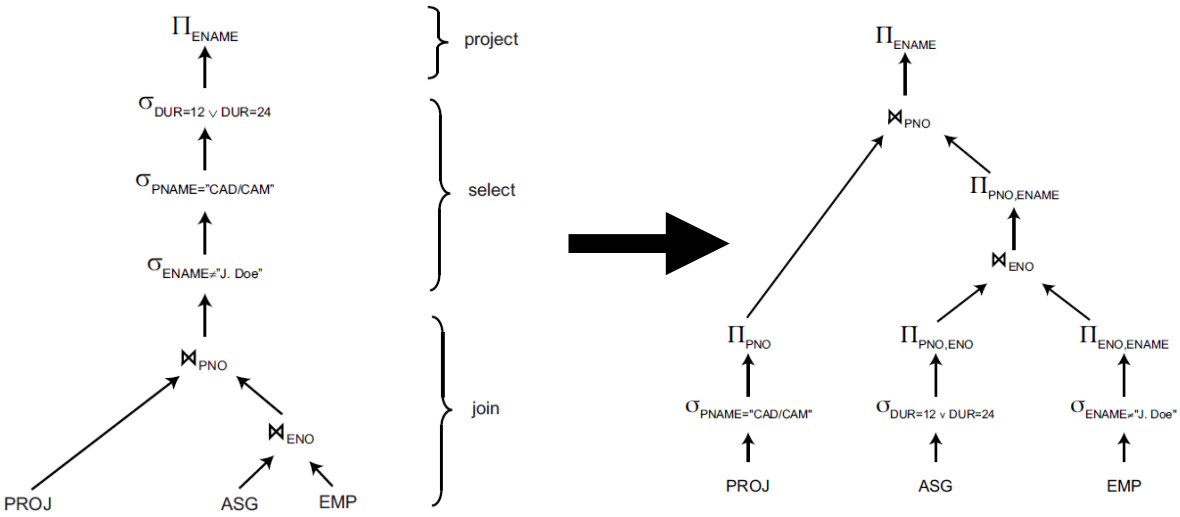

Árvore Equivalentes:

- Fase de otimização: comparação de todas as árvores possíveis
- # árvores possíveis —> ∞
- A ideia consiste em aplicar as regras de transformação para que as “más árvores” sejam eliminadas
- Vantagens
    1. Separação de operações unárias (simplifica a consulta)
    2. Agrupamento de operações unárias (acesso à relação de uma vez)
    3. Comutação (permutação) de operações unárias e binárias (operações de seleção podem ser executadas primeiro)
    4. Ordenação das operações binárias (usada na otimização de consultas)

Localização de Dados Distribuídos

• Localização de dados fragmentados entre as unidades de armazenamento do SGBDD
• Converter uma consulta algébrica sobre relações globais numa consulta algébrica expressa sobre fragmentos físicos

• Programa de localização
  - É um programa em álgebra relacional cujos operandos são os fragmentos
  - Obtido a partir das regras de reconstrução das consultas globais

• Cada relação global é substituída pelo seu programa de localização
• A consulta resultante é chamada de "consulta localizada"
• A "consulta localizada" ainda pode ser simplificada e reestruturada por meio da aplicação de **regras de redução**

Regras de redução:

- Redução da Fragmentação Horizontal

- A função de fragmentação horizontal faz a distribuição duma relação com base nos predicados de seleção (o operador de reconstrução é a união)
- As técnicas de redução para a fragmentação horizontal procuram determinar quais sub-árvores produzirão relações vazias para que sejam removidas

- Redução com seleção (select)

Dada uma relação R que foi fragmentada horizontalmente como R_1, R_2, ..., R_w, onde $R_j = sel_{pj}(R)$, a regra pode ser enunciada formalmente como:

$$\textbf{Rule 1: } \sigma_{p_i}(R_j) = \phi \text{ if } \forall x \text{ in } R : \neg(p_i(x) \wedge p_j(x))$$

onde p_i e p_j são predicados de seleção, x denota um tuplo e p(x) denota "predicado p(x) válido para x"

➡ Um predicado da consulta é aplicado a um fragmento e retorna um conjunto vazio!

EXEMPLO

EMP(ENO, ENAME, TITLE)

$$EMP_1 = \sigma_{ENO \leq "E3"}(EMP)$$
$$EMP_2 = \sigma_{"E3" < ENO \leq "E6"}(EMP)$$
$$EMP_3 = \sigma_{ENO > "E6"}(EMP)$$

➡ Fragmentação Horizontal

$$EMP = EMP_1 \cup EMP_2 \cup EMP_3$$

➡ Programa de Localização (a evitar)

Considere a consulta:

```
SELECT *
FROM   EMP
WHERE  ENO = "E5"
```

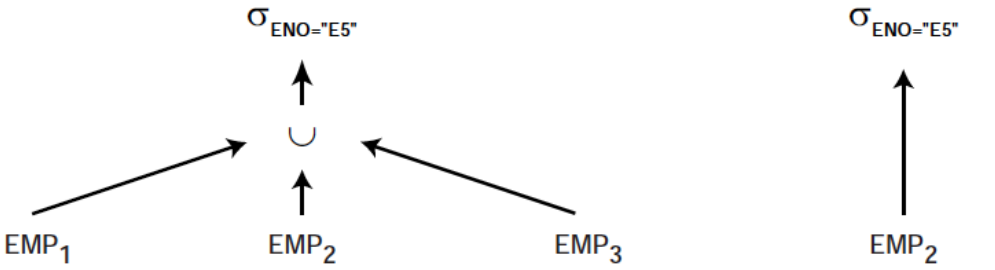

(a) Localized query (b) Reduced query

➡ Os predicados de EMP1 e EMP3 são contraditórios com o predicado da seleção da consulta, logo os fragmentados podem ser eliminados

- **Redução com junção (join)**
- Distribuir junções sobre uniões e eliminar junções inúteis
- Primeiro, as uniões devem ser movidas para cima da árvore para que as junções apareçam
- A distribuição da junção sobre a união pode ser expressa como:

$$(R_1 \cup R_2) \bowtie S = (R_1 \bowtie S) \cup (R_2 \bowtie S)$$

onde Ri são fragmentos de R, e S é uma relação
- Segundo, as junções inúteis devem ser removidas
- Supondo que os R_i e R_j sejam definidos respetivamente de acordo com os predicados p_i e p_j sobre o mesmo atributo, a regra de simplificação pode ser expressa da seguinte maneira:

Rule 2: $R_i \bowtie R_j = \phi$ if $\forall x$ in $R_i, \forall y$ in $R_j : \neg(p_i(x) \wedge p_j(y))$

EXEMPLO

```
SELECT *
FROM   EMP, ASG
WHERE  EMP.ENO = ASG.ENO
```

$$ASG_1 = \sigma_{ENO \leq "E3"}(ASG)$$
$$ASG_2 = \sigma_{ENO > "E3"}(ASG)$$

➡ ASG: Funcionários e os projetos onde eles trabalham

$$EMP_1 = \sigma_{ENO \leq "E3"}(EMP)$$
$$EMP_2 = \sigma_{"E3" < ENO \leq "E6"}(EMP)$$
$$EMP_3 = \sigma_{ENO > "E6"}(EMP)$$

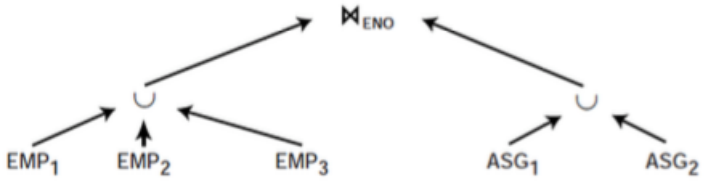

(A) LOCALIZED QUERY

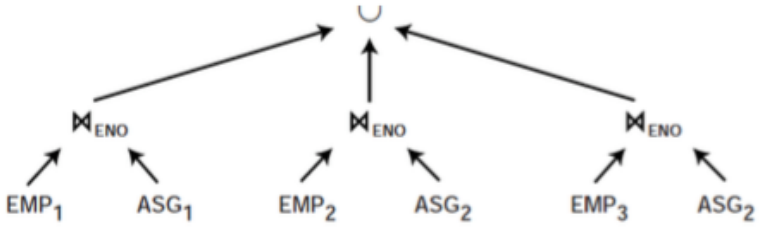

(B) REDUCED QUERY

➡ As junções inúteis são eliminadas e as que ficam podem ser implementadas em paralelo

-Redução da Fragmentação Vertical

- O programa de localização para uma relação fragmentada verticalmente consiste na junção dos fragmentos sobre o atributo comum
- Consultas podem ser reduzidas pela determinação das relações intermédias inúteis e pela remoção das sub-árvores que as produzem
- Dada uma relação R definida sobre atributos A = {A_1, ..., A_n}, fragmentada verticalmente como $R_i = \pi_{A'}(R)$, onde A' está contido em A, a regra pode ser expressa como:

Rule 3: $\Pi_{D,K}(R_i)$ is useless if the set of projection attributes D is not in A'.

EXEMPLO

```
SELECT ENAME
FROM   EMP
```

$$EMP_1 = \Pi_{ENO,ENAME}(EMP)$$
$$EMP_2 = \Pi_{ENO,TITLE}(EMP)$$

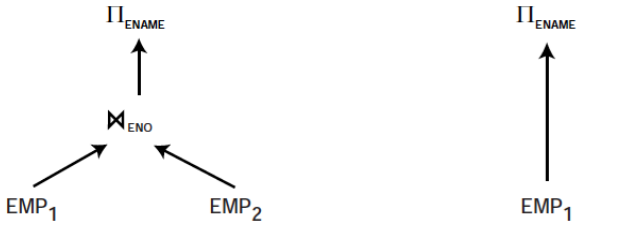

(A) LOCALIZED QUERY (B) REDUCED QUERY

➡ O fragmento EMP2 não tem ENAME!

- Redução para Fragmentação Derivada

- A operação de junção pode ser otimizada quando as relações foram fragmentadas usando o mesmo predicado de seleção
  - A junção de duas relações pode ser implementada como a união das junções parciais (as junções parciais podem ser executadas em paralelo)
- Só vale quando os predicados usados na fragmentação são os mesmos!

Fragmentação derivada

- Uma maneira de distribuir duas relações para que o processamento conjunto da seleção e junção seja otimizado
- Os predicados não são os mesmos!
- Consultas definidas sobre fragmentos derivados podem ser reduzidos
- Este tipo de fragmentação é feita para otimizar junções
- Uma regra útil consiste em:
  1. Distribuir as junções sobre as uniões (Substituir junções por uniões de junções parciais)
  2. Aplicar a regra 2 para redução de fragmentação horizontal

EXEMPLO

$ASG(ENO, PNO, RESP, DUR)$ → Informações sobre os projetos onde os empregados estão alocados

$$ASG_1 = ASG \ltimes_{ENO} EMP_1$$
$$ASG_2 = ASG \ltimes_{ENO} EMP_2$$

→ Fragmentação derivada

$$EMP_1 = \sigma_{TITLE="Programmer"}(EMP)$$
$$EMP_2 = \sigma_{TITLE\neq"Programmer"}(EMP)$$

$ASG = ASG_1 \cup ASG_2$ → Programa de localização

```
SELECT *
FROM   EMP, ASG
WHERE  ASG.ENO = EMP.ENO
AND    TITLE = "Mech. Eng."
```

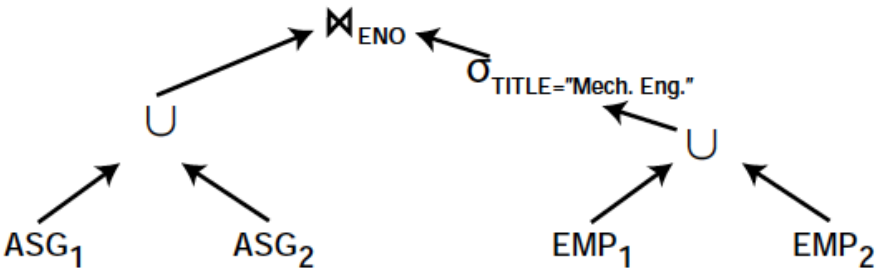

(A) LOCALIZED QUERY

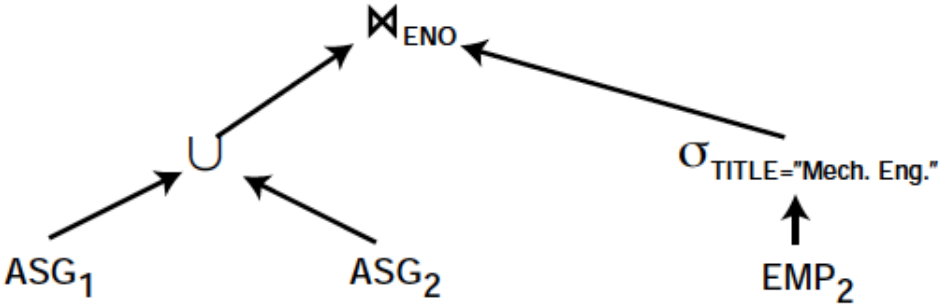

(B) QUERY AFTER PUSHING SELECTION DOWN

➡ EMP1 é removido porque só tem programadores

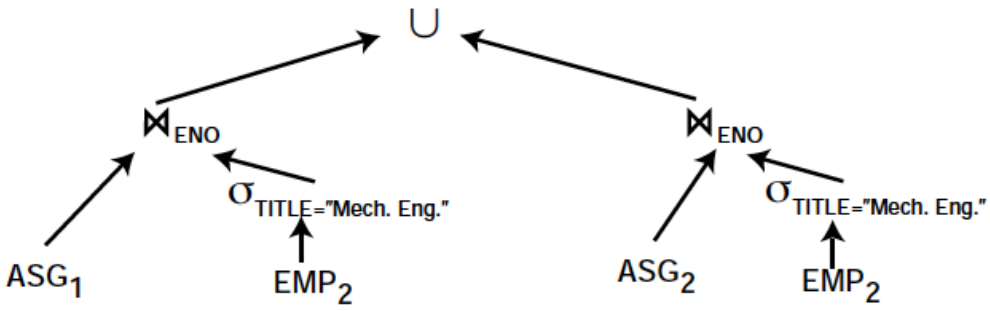

(C) QUERY AFTER MOVING UNIONS UP

➡ A sub-árvore da esquerda é eliminada porque os predicados dos fragmentos são contraditórios

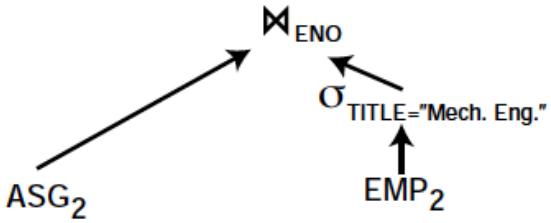

(D) REDUCED QUERY AFTER ELIMINATING THE LEFT SUBTREE

- **Redução para Fragmentação Híbrida**

$$EMP_1 = \sigma_{ENO \leq "E4"}(\Pi_{ENO,ENAME}(EMP))$$
$$EMP_2 = \sigma_{ENO > "E4"}(\Pi_{ENO,ENAME}(EMP))$$
$$EMP_3 = \Pi_{ENO,TITLE}(EMP)$$

➡ Fragmentação híbrida

$$EMP = (EMP_1 \cup EMP_2) \bowtie_{ENO} EMP_3$$

➡ Programa de localização

EXEMPLO

```
SELECT ENAME
FROM   EMP
WHERE  ENO="E5"
```

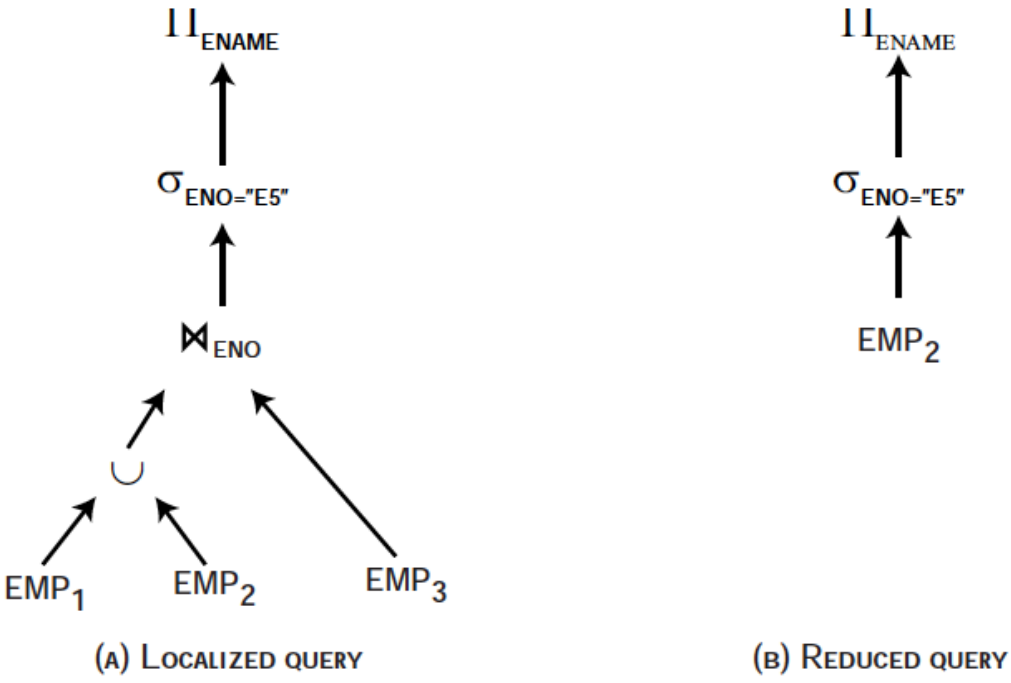

(A) LOCALIZED QUERY (B) REDUCED QUERY

➡ O fragmento EMP1 é eliminado por causa da seleção
➡ O fragmento EMP3 é eliminado por causa da projeção

Conclusão

- Decomposição de consultas e localização de dados são duas funções sucessivas
- Muitas consultas algébricas podem ser equivalentes à mesma consulta de entrada
  - Abordagens ingénuas são ineficientes
- Reestruturação com a utilização de regras e regras de redução
- Mais otimizações são geradas nas camadas subsequentes, considerando informações sobre o ambiente de processamento